一．流程图

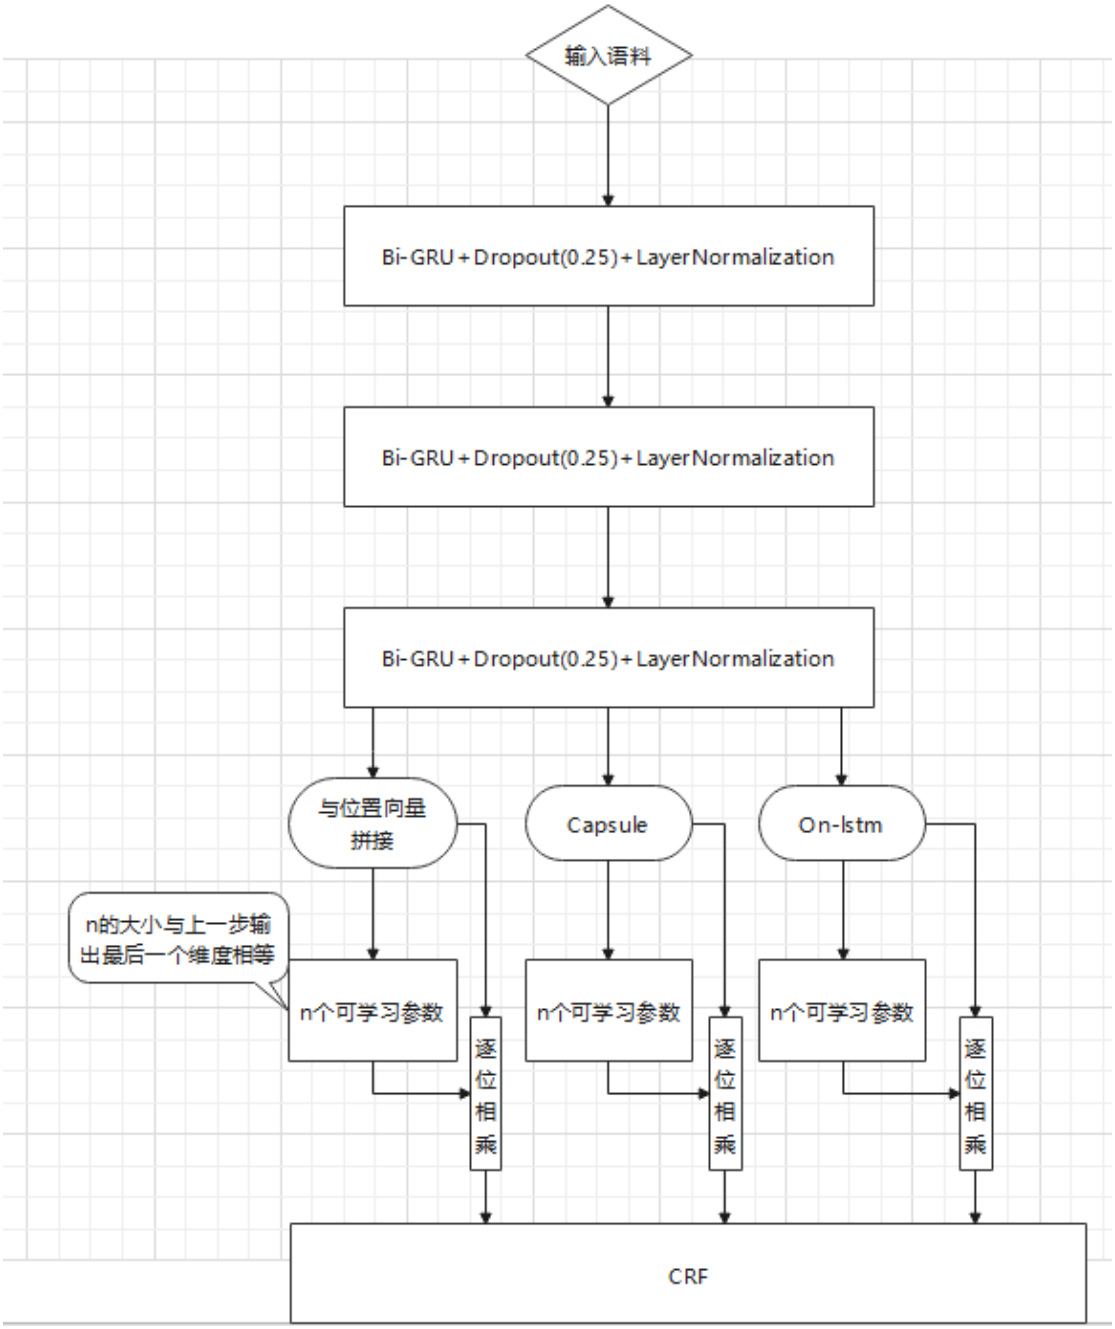

二．按步骤具体说明

1. Bi-GRU+Dropout(0.25)+LayerNormalization

这三层 Bi-GRU+Dropout(0.25)+LayerNormalization 为编码层，层数可以增加也可以减少，层数越多肯定效果会越好，但是平衡训练时间和效果，选择了三层。在增加层数效果会有所提升，但是提升的很有限，而单批次训练所需的时间却增长的很多，而且随着层数的增加，所需使用的正则化手段要增多，这进一步增加了训练的时间成本。GRU 的 units 参数在存在 Bi 的时候可以设置为输入向量最后一维的一半，当不存在 Bi 的时候可以设置的与输入向量最后一维相等，按经验来说该种方案可能不是最优方案但是比较省心，而且随着层数的增加，参数带来的差别也在逐渐缩小，若想获取最优方案，需要不断的更换参数训练模型，虽然可以写个循环自动化的完成参数的选择，但是很费时间，个人真的

伤不起。

2. 位置向量

   位置向量的实现方法有很多，我常用的有两种，第一种是利用公式直接生成，来自<<Attention is all you need>>，如图 1 所示。第二种是将语料中每个词用其索引替换，比如{Attention, is, al,l you, need}替换后为{0, 1, 2, 3}，之后放入一个 embedding 层，该层的输出即当作位置向量的编码，优势是该 embedding 层也会得到训练，使得位置向量不是一成不变固定的编码。本次我使用的是第一种，经过实验第一种效果优于第二种。位置向量与语料的组合方式也有很多，这是实验了加、乘和拼接，效果最好的是拼接方法。

$$\begin{cases} PE_{2i}(p) = \sin\left(p/10000^{2i/d_{pos}}\right) \\ PE_{2i+1}(p) = \cos\left(p/10000^{2i/d_{pos}}\right) \end{cases}$$

3. n 个可学习参数

   比如上一层的输出 shape 为(32,32,4)，那么 n 就为 4。具体做法是将上一层的输出输入至 4 个 unite 参数为 1 的 Dense 中，将结果拼接起来，形成 shape 为(32,32,4)的输出，并与上一层的输出逐位相乘，最后与其他通道的结果相加，送入 CRF 层得出结果。

4. 优化器

   优化器使用的是带自适应参数功能的 Adam 优化器，比较省心，结果不是最优但是不用耗费大量时间调参数。

三．结果

所用语料为 semeval 14 和 15，使用 bert 的预训练词向量 f1 最高为 0.83，不使用 bert 的预训练词向量仅仅使用 word2vec，f1 最高为 0.78。

四．引用

以上用到的很多技术方法在苏老师的科学空间(https://kexue.fm/)中均有非常详细的讲解，这里也非常感谢苏老师。